EIXO VIII · LER DADOS SEM SER ENGANADO — AULA 8.13

Dois grupos com a mesma média podem ser completamente diferentes?

> *A média te diz onde está o centro. Ela não te diz se as pessoas estão perto dele. E é justamente a distância até o centro — não o centro — que decide se um remédio funciona, se um investimento é seguro e se um piloto pousa o avião.*

Aula 8.13 — Dispersão: a matemática do espalhamento

A ÂNCORA

Você é o coordenador de uma escola e precisa decidir qual professor será promovido. Chegam as notas da prova final das duas turmas, cada uma com cinco alunos:

Turma	A_1	A_2	A_3	A_4	A_5	Média
Turma X	6	6	6	6	6	**6,0**
Turma Y	0	3	6	9	12	**6,0**

Mesma média: 6,0. Mesma mediana: 6,0. Mesma soma: 30.

Se você resumir essas turmas por qualquer medida da aula anterior, elas são **matematicamente idênticas**. O relatório que sobe para a diretoria diz: "desempenho equivalente".

Mas olhe de novo. Na Turma X, **todo mundo aprendeu a mesma coisa**. Na Turma Y, existe um aluno que tirou zero e um aluno que tirou nota máxima na mesma sala, ouvindo o mesmo professor. Essas turmas não são parecidas. Elas são realidades **opostas**.

O relatório não estava errado. Estava incompleto de um jeito que muda a decisão. E o que faltava nele não é um dado novo — é uma pergunta nova.

A DESCONSTRUÇÃO

O senso comum diz: "média é o resumo dos dados; se precisar de mais detalhe, olho os números um por um."

Isso é uma armadilha dupla. Primeiro, porque com mil observações você **não vai** olhar um por um. Segundo — e esse é o ponto sofisticado — porque **existe um segundo número que resume os dados**, e ele mora numa dimensão diferente da média.

Perceba a estrutura lógica: toda medida de posição (média, mediana, moda) responde à pergunta **"onde?"**. Nenhuma delas, por construção, é capaz de responder **"quão espalhado?"** — porque essa é uma informação de outra natureza.

> **O ERRO DE ARQUITETURA, NÃO DE CONTA**
>
> A média é uma **medida de posição**. Pedir a ela que informe sobre espalhamento é como pedir o endereço de uma cidade e reclamar que não veio o tamanho dela. São duas coordenadas independentes da descrição de qualquer conjunto de dados:
>
> **POSIÇÃO** (onde está o centro) + **DISPERSÃO** (a que distância dele estão os dados)
>
> Um conjunto de dados descrito só pela primeira é um conjunto de dados que você não conhece.

E aqui está o segredo que a maioria dos seus colegas nunca vai perceber: **dispersão não é ruído; dispersão é informação**. Em finanças, ela se chama **risco**. Em engenharia, **tolerância**. Em medicina, **variabilidade de resposta**. Em fabricação, **controle de qualidade**. Sempre é o mesmo número.

A ENGENHARIA DO CONCEITO

Parte 1 · A tentativa ingênua — e por que ela falha

Se dispersão é "distância até o centro", a ideia óbvia é: calcule a distância de cada dado até a média e faça a média dessas distâncias.

Vamos testar na Turma Y, com $\overline{x} = 6$. Os desvios $(x_i - \overline{x})$ são:

$$-6, \quad -3, \quad 0, \quad +3, \quad +6$$

Some: $-6 - 3 + 0 + 3 + 6 = 0$.

A soma dos desvios em relação à média é sempre zero, para qualquer conjunto de dados. Sem exceção.

Isso não é coincidência — é a **definição** da média se manifestando. Prove você mesmo em três linhas:

$$\sum (x_i - \overline{x}) = \sum x_i - n\overline{x} = n\overline{x} - n\overline{x} = 0$$

Lembre de 8.11: a média é o **centro de massa**. Os desvios são os torques nos dois lados da gangorra, e o centro de massa é justamente o ponto onde eles se cancelam. A soma dar zero é a prova de que a média está no lugar certo — e é exatamente por isso que ela é **inútil** como medida de espalhamento.

Precisamos matar os sinais. Existem duas formas de fazer isso, e a escolha entre elas explica toda a estatística que vem depois.

Parte 2 · Duas saídas: módulo ou quadrado

Rota	Como mata o sinal	Consequência
Módulo	$\lvert x_i - \overline{x} \rvert$ → **desvio médio**	Intuitivo, mas o módulo é algebricamente hostil (não deriva, não expande). Praticamente abandonado.

Rota	Como mata o sinal	Consequência
Quadrado	$(x_i - \overline{x})^2 \longrightarrow$ **variância**	Algebricamente domesticável, penaliza mais os desvios grandes. É a rota que a estatística escolheu.

AS TRÊS FÓRMULAS — E A LÓGICA QUE AS UNE

Desvio médio:

$$\mathrm{DM} = \frac{\sum |x_i - \overline{x}|}{n}$$

Variância:

$$\sigma^2 = \frac{\sum (x_i - \overline{x})^2}{n}$$

Desvio padrão:

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{\sum (x_i - \overline{x})^2}{n}}$$

Todas são **médias de distâncias**. A variância é a média dos quadrados das distâncias — e é por isso que ela vem numa unidade absurda: se os dados estão em reais, a variância está em "reais ao quadrado". Não existe interpretação física para isso.

É por essa única razão que a raiz quadrada existe na fórmula do desvio padrão: para trazer o resultado de volta à unidade original dos dados. O desvio padrão é a variância **traduzida para a língua dos dados**.

Parte 3 · Fechando o caso da âncora

Turma X: todos os desvios são zero. Logo $\sigma^2 = 0$ e $\sigma = 0$.

Turma Y: desvios $-6, -3, 0, 3, 6$. Ao quadrado: $36, 9, 0, 9, 36$.

$$\sigma^2 = \frac{36 + 9 + 0 + 9 + 36}{5} = \frac{90}{5} = 18 \quad \Rightarrow \quad \sigma = \sqrt{18} \approx 4,24$$

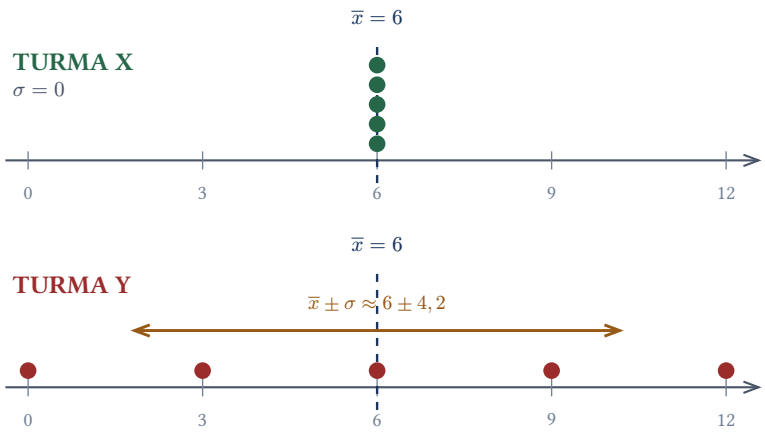


Fig. 1 — O desvio padrão é **uma largura**, medida na mesma unidade dos dados. Ele responde: "tomando um aluno ao acaso, quantos pontos ele costuma estar longe de 6?". Na Turma X, zero pontos — homogeneidade total. Na Turma Y, cerca de 4,2 pontos — a nota "média" não descreve ninguém. Note ainda: $\sigma = 0$ só acontece quando **todos** os dados são iguais, e σ nunca é negativo.

Agora o relatório fica honesto: **X = (6,0 ; 0)** e **Y = (6,0 ; 4,24)**. Dois números, e as turmas deixam de ser confundíveis.

Parte 4 · A amplitude: a medida frágil que ainda serve

Amplitude total: $A = x_{\text{máx}} - x_{\text{mín}}$.

Na Turma Y: $12 - 0 = 12$. Rápido, intuitivo — e péssimo, porque **usa apenas dois dados de mil** e é totalmente dominada pelos extremos. Um único outlier reescreve a amplitude e não move quase nada o desvio padrão.

Serve como triagem grosseira, nunca como conclusão.

Parte 5 · Quartis e boxplot: dispersão que não teme outliers

A mediana partiu os dados em duas metades. Repita o corte dentro de cada metade e você obtém os **quartis**:

- **Q_1** — 25% dos dados abaixo dele
- **Q_2** — a própria mediana, 50% abaixo
- **Q_3** — 75% dos dados abaixo dele

E daí nasce a versão **robusta** da dispersão:

$$\text{AIQ} = Q_3 - Q_1 \quad \text{(amplitude interquartil: a largura dos 50\% centrais)}$$

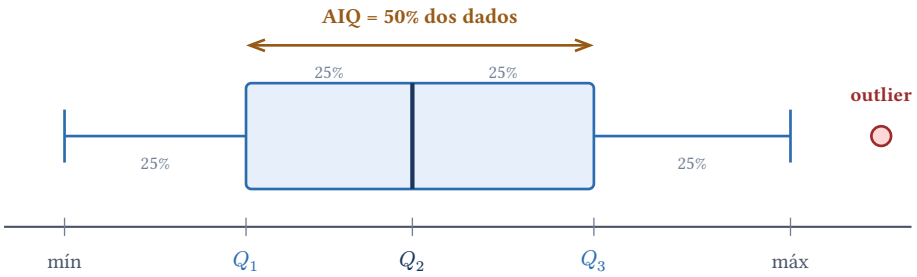


Fig. 2 — Cada uma das quatro regiões contém **o mesmo número de observações** — nunca o mesmo comprimento. Logo, um bigode longo não significa "muitos dados ali": significa que aqueles 25% estão **espalhados**. Caixa deslocada para a esquerda com bigode direito comprido = assimetria à direita, o padrão da renda que você viu em 8.12.

Parte 6 · O coeficiente de variação: o desvio padrão é grande ou pequeno?

Pergunta decisiva: um desvio padrão de R$ 500 é grande?

Se for a variação de preço de um **chocolate**, é absurdo. Se for de um **apartamento**, é irrelevante. **O desvio padrão sozinho não pode ser julgado** — ele é uma quantidade absoluta, e você aprendeu em 1.11 que comparação séria é **relativa**.

$$\text{CV} = \frac{\sigma}{\overline{x}} \times 100\%$$

O QUE O CV RESOLVE

O CV é **adimensional**: as unidades se cancelam. Isso permite comparar a dispersão de conjuntos com escalas ou grandezas completamente diferentes — peso de recém-nascidos contra faturamento de empresas, se você quiser.

Leitura prática: menor CV = maior **homogeneidade / regularidade / previsibilidade**. Maior CV = maior **risco / irregularidade**.

Na Turma Y: $\text{CV} = 4,\frac{24}{6} \times 100\% \approx 70,7\%$. Um CV de 70% em notas escolares é um sinal vermelho: aquela sala não é uma turma, são dois grupos convivendo.

Parte 7 · O uso adulto: dispersão é risco

Dois investimentos, mesmo retorno médio de 10% ao ano. O primeiro tem $\sigma = 1\%$; o segundo, $\sigma = 25\%$.

Eles **não são equivalentes**, e nenhum gestor no mundo trataria assim. O segundo pode entregar -15% num ano em que você precisava do dinheiro. Em finanças, o desvio padrão do retorno **tem um nome próprio**: volatilidade. É a definição operacional de risco.

Você não escolhe pela média. Você escolhe pelo par (média, desvio padrão) — porque a média é o que você espera, e o desvio padrão é o quanto a realidade tem licença para te desobedecer.

A REGRA DO JOGO

O que você leva desta aula para a prova

1. **Descrever dados exige dois números:** uma medida de **posição** (onde está o centro) e uma de **dispersão** (a que distância dele estão os dados).
2. $\sum(x_i - \overline{x}) = 0$ **sempre.** É por isso que os desvios precisam ser elevados ao quadrado (ou tomados em módulo).
3. **Variância** $\sigma^2 = \left(\sum (x_i - \overline{x})^2\right)/n$: média dos quadrados dos desvios. Vem em **unidade ao quadrado**, logo não é interpretável diretamente.
4. **Desvio padrão** $\sigma = \sqrt{\sigma^2}$: existe só para devolver o resultado à unidade original dos dados. É uma **largura típica** em torno da média.
5. $\sigma \geq 0$ **sempre, e** $\sigma = 0$ **se e somente se todos os dados são iguais.**
6. **Amplitude** = máx − mín: usa dois dados só, refém de outliers. **AIQ** $= Q_3 - Q_1$: robusta, mede a largura dos 50% centrais.
7. **Quartis dividem os dados em quatro grupos de igual quantidade**, nunca de igual comprimento. No boxplot, bigode longo = dados espalhados naquele quarto.
8. **CV** $= (\sigma/\overline{x}) \times 100\%$: adimensional, único jeito legítimo de comparar dispersões de escalas diferentes. Menor CV = mais homogêneo.
9. Somar uma constante a todos os dados **muda a média e não muda o desvio padrão**. Multiplicar todos por $k > 0$ multiplica **ambos** por k.
10. Em contexto real, **desvio padrão = risco, volatilidade, tolerância, irregularidade**. Sempre o mesmo número, nomes diferentes.

OQPS — A LINHA DE CHEGADA

Sem consultar. Respostas curtas e técnicas.

1. Demonstre que a soma dos desvios em relação à média é nula e explique por que esse fato torna obrigatório o uso de quadrados (ou módulos) no cálculo da dispersão.
2. Diferencie variância e desvio padrão, indicando qual é a única finalidade da raiz quadrada na definição do desvio padrão.
3. Explique por que a amplitude total é uma medida frágil de dispersão e qual medida a substitui quando existem outliers.
4. Defina os quartis e explique por que, num boxplot, um bigode mais longo não indica maior quantidade de dados naquela região.
5. Escreva a expressão do coeficiente de variação e justifique por que o desvio padrão isolado não permite comparar a dispersão de dois conjuntos de grandezas distintas.

GABARITO OQPS

1. $\sum(x_i - \overline{x}) = \sum x_i - n\overline{x}$; como $\overline{x} = (\sum x_i)/n$, tem-se $\sum x_i = n\overline{x}$, logo a expressão vale $n\overline{x} - n\overline{x} = 0$. Como desvios positivos e negativos se cancelam exatamente (a média é o centro de massa), a média simples dos desvios é sempre zero e não mede nada. Elevar ao quadrado ou tomar o módulo elimina o sinal, preservando a magnitude da distância.
2. A **variância** é a média dos quadrados dos desvios, $\sigma^2 = \left(\sum(x_i - \overline{x})^2\right)/n$, e por isso é expressa na unidade dos dados **ao quadrado** — sem interpretação física direta. O **desvio padrão** é $\sigma = \sqrt{\sigma^2}$. A raiz quadrada tem uma única finalidade: **retornar a medida à unidade original dos dados**, tornando-a interpretável como uma distância típica em relação à média.
3. Porque a amplitude (máx − mín) utiliza apenas duas observações do conjunto, ignorando todas as demais, e depende exatamente dos dois valores mais extremos — logo um único outlier a distorce completamente. Ela é substituída pela **amplitude interquartil**, $\text{AIQ} = Q_3 - Q_1$, que mede a largura dos 50% centrais e é robusta a valores extremos.
4. Os quartis são os três valores que dividem o conjunto ordenado em quatro partes com o **mesmo número de observações** (25% cada): Q_1 (25% abaixo), Q_2 = mediana (50% abaixo) e Q_3 (75% abaixo). Como cada região contém quantidade fixa de dados, o comprimento do bigode reflete a **amplitude** ocupada por aqueles 25% — ou seja, bigode longo significa que aquele quarto dos dados está mais **espalhado**, não mais numeroso.
5. $\text{CV} = (\sigma/\overline{x}) \times 100\%$. O desvio padrão é uma medida **absoluta**, expressa na unidade e na escala dos dados; assim, $\sigma = 500$ é enorme para preços de chocolate e desprezível para preços de imóveis. O CV é uma razão entre duas quantidades de mesma unidade, logo é **adimensional**, e expressa a dispersão como fração do próprio centro — permitindo comparação legítima entre conjuntos de escalas ou grandezas diferentes.

A RESPOSTA, EM UMA FRASE

Sim — e podem ser opostos: a média fixa apenas onde está o centro, de modo que só as medidas de dispersão (variância, desvio padrão, AIQ e coeficiente de variação) revelam se os dados estão colados nesse centro ou espalhados a distâncias que tornam a média uma descrição de ninguém.

Você agora tem os dois números que descrevem qualquer conjunto de dados. E é exatamente aí que começa o problema seguinte:

> *Um jornal publica um gráfico de barras em que o eixo vertical começa em 45% em vez de zero. Duas barras quase idênticas — 47% e 49% — aparecem uma com o dobro da altura da outra. Nenhum número foi falsificado. Nenhuma média foi manipulada. Nenhuma conta está errada.*
>
> *Você acaba de aprender a **calcular** dispersão. Em **8.14** você aprende que quem desenha o gráfico controla a dispersão que seus olhos **percebem** — eixo truncado, escolha maliciosa de intervalo de classe, escala esticada, amostra viesada. É a aula em que a estatística deixa de ser conta e passa a ser autodefesa.*

A seguir: 8.14 — Como um gráfico honesto pode contar uma mentira?