EIXO VIII · LER DADOS SEM SER ENGANADO — AULA 8.14

Como um gráfico honesto pode contar uma mentira?

> *Não existe gráfico neutro. Todo gráfico é uma frase escrita por alguém que decidiu onde o eixo começa, quão largo é o intervalo e quem entrou na amostra. Essas três decisões cabem antes da conta — e é nelas que a mentira mora.*

Aula 8.14 — A anatomia da mentira estatística

A ÂNCORA

Manchete de capa, letras garrafais:

> ***DESEMPREGO DISPARA: veja o salto assustador do último trimestre.***

Ao lado, um gráfico de barras. A segunda barra tem visualmente **o triplo** da altura da primeira. Seu cérebro registra: catástrofe.

Os números impressos nas barras são 7,8% e 8,1%.



Fig. 1 — Os **quatro números são idênticos** nos dois gráficos. Nenhum dado foi inventado, apagado ou arredondado. O que mudou foi apenas **onde o eixo vertical começa** — e com isso a razão entre as alturas passou de $\approx 1,04$ para $3,0$. Guarde a regra física: em gráfico de barras, o cérebro compara **área**, não a posição do topo. Truncar o eixo destrói a proporcionalidade entre área e valor.

Você foi enganado por um gráfico em que **não existe um único número falso**. Esse é o crime perfeito da estatística: ele não precisa de mentira.

A DESCONSTRUÇÃO

O senso comum diz: "gráfico é objetivo; texto é que é opinião. Se os números estão certos, o gráfico está certo."

Isso é exatamente ao contrário. **O texto você lê com desconfiança; o gráfico você lê com o sistema visual** — o mesmo circuito que estima tamanho de predador em 200 milissegundos, sem passar pela consciência crítica. Quando você "vê" que uma barra é o triplo da outra, você não conclui isso: você **percebe**. E percepção não se argumenta.

O MECANISMO DO GOLPE

Toda mentira gráfica funciona pela **dissociação entre o dado e o seu encoding visual**.

DADO (verdadeiro) → **ESCOLHA DE REPRESENTAÇÃO** (arbitrária) → **PERCEPÇÃO** (falsa)

A auditoria de veracidade que você aprendeu na escola inspeciona apenas a **primeira** caixa. A fraude mora na segunda — e ela é composta de decisões que **não aparecem no gráfico**: onde começa o eixo, qual a largura do intervalo, quem entrou na amostra, qual o recorte de tempo.

E o mais desconfortável: essas escolhas **são inevitáveis**. Alguém tem que decidir. Não existe o gráfico "sem escolhas" — logo, não existe gráfico neutro. Sua tarefa não é achar o gráfico puro. É **auditar as escolhas**.

A ENGENHARIA DO CONCEITO

Parte 1 · Antes do gráfico existe a tabela de frequência

Todo gráfico de distribuição nasce de uma tabela, e é nela que a primeira decisão é tomada. Quatro colunas obrigatórias:

Classe	f_i (absoluta)	f_r (relativa)	F_i (acumulada)	ponto médio
$[0;2)$	8	16%	8	1
$[2;4)$	17	34%	25	3
$[4;6)$	15	30%	40	5
$[6;8)$	10	20%	50	7
Total	**50**	**100%**	—	—

VOCABULÁRIO QUE A PROVA COBRA

- **Frequência absoluta** f_i: quantas observações caíram na classe.
- **Frequência relativa** $f_r = f_i/n$: a proporção — a única comparável entre grupos de tamanhos diferentes (é 1.7 e 1.11 reaparecendo).
- **Frequência acumulada** F_i: soma até aquela classe. É o que responde "quantos ficaram abaixo de 6?" — e é a ferramenta natural para achar mediana e quartis.
- **Amplitude de classe** h: a largura do intervalo. **Escolha humana, não dado.**
- **Ponto médio**: representante da classe quando você perdeu os valores originais.

Ao agrupar em classes você destrói informação de propósito — troca precisão por legibilidade. A pergunta honesta nunca é "está agrupado?", mas "quanto foi destruído, e a escolha do corte muda a conclusão?"

Parte 2 · Histograma não é gráfico de barras

Confusão que derruba muito candidato:

	Gráfico de barras	Histograma
Variável	Qualitativa / discreta (categorias)	Quantitativa **contínua** (intervalos)
Barras	Separadas — categorias não se tocam	**Colgadas** — os intervalos são contíguos
Ordem	Pode ser reordenada livremente	Fixa: é uma reta numérica
Informação está na	Altura	**Área** (altura × largura)

A última linha é a que ninguém sabe — e é a chave da fraude seguinte. No histograma, o que representa a quantidade de dados é a **área** do retângulo. Se as classes tiverem larguras diferentes e você desenhar a altura como frequência bruta, uma classe duas vezes mais larga aparece com o dobro da área — e você acabou de duplicar visualmente dados que não existem.

Parte 3 · A escolha do intervalo cria e apaga fenômenos

Este é o truque mais sofisticado do capítulo. Os **mesmos dados**, agrupados com larguras diferentes, produzem formas de distribuição incompatíveis.

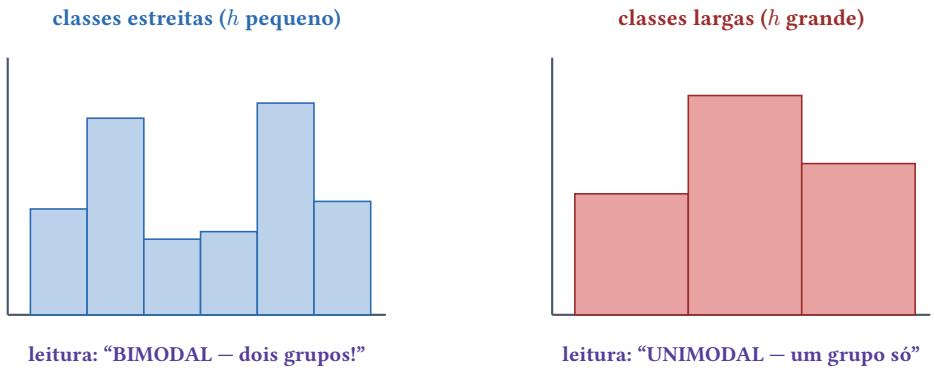


Fig. 2 — Mesmo conjunto de dados, duas larguras de classe. À esquerda a distribuição parece ter **dois picos** (dois perfis distintos convivendo); à direita, um único pico bem-comportado. Nenhum dos dois é "o gráfico errado" — ambos são consequências legítimas de uma escolha arbitrária. Moral operacional: **antes de afirmar que uma distribuição é bimodal ou assimétrica, verifique se essa forma sobrevive a uma mudança de largura de classe.** Forma que não é robusta é artefato, não fenômeno.

Parte 4 · O catálogo das fraudes visuais

> **1 · EIXO TRUNCADO (BASELINE SHIFT)**
>
> Eixo vertical não começa em zero. Amplifica diferenças irrelevantes. **Sinal de alerta:** o primeiro rótulo do eixo y não é 0. **Legítimo** apenas em séries temporais de variável que nunca chega perto de zero (temperatura corporal, cotação cambial) — **e sempre com marca de quebra explícita**.

2 · ESCALA NÃO LINEAR DISFARÇADA

Eixo em escala logarítmica (3.10) sem aviso: crescimento explosivo aparece como reta mansa. Ou o inverso — eixo linear para dado que varia em ordens de grandeza, criando "explosão" onde há crescimento estável. **Sinal de alerta:** espaçamento desigual dos rótulos $(1, 10, 100, 1000)$.

3 · A FRAUDE DA SEGUNDA DIMENSÃO

Substituir a barra por um **desenho** (uma moeda, uma pessoa, um barril) e dobrar **a altura** do desenho. Como o desenho é escalado proporcionalmente, a **largura também dobra** — e a área quadruplica. Você aprendeu isso em 4.5: escala k multiplica área por k^2 e volume por k^3. Um pictograma 3D com o dobro da altura ocupa **oito vezes** o volume visual para representar **o dobro** do dado.

4 · RECORTE DE TEMPO (CHERRY-PICKING)

Escolher o intervalo de datas que produz a inclinação desejada. Uma série que sobe 20 anos e cai 8 meses vira "queda histórica" se o gráfico começar 8 meses atrás. **Pergunta-antídoto:** por que a série começa exatamente nessa data?

5 · EIXOS DUPLOS COM ESCALAS AJUSTADAS

Duas variáveis, dois eixos y independentes, cada um calibrado até as curvas se abraçarem. Produz correlação visual entre coisas sem relação alguma. **Correlação não é causalidade — e correlação desenhada não é nem correlação.**

6 · FREQUÊNCIA ABSOLUTA EM VEZ DE RELATIVA

"Morreram mais pessoas vacinadas do que não vacinadas." Verdade — se 95% da população está vacinada. Comparar contagens brutas entre grupos de tamanhos diferentes é a fraude aritmética mais comum do país. **Antídoto: taxa, sempre taxa.**

Parte 5 · A fraude que nenhum gráfico revela: a amostra viesada

Todas as anteriores estão **no desenho**. Esta está **antes** dele, e nenhuma auditoria visual a detecta.

Viés de amostragem é quando o processo de coleta favoreceu sistematicamente certas respostas. Alguns padrões clássicos:

- **Autosseleção:** enquete de site, votação em rede social. Só responde quem tem opinião forte — logo a distribuição obtida é a das opiniões intensas, não a da população.
- **Viés do sobrevivente:** estudar apenas o que restou. "90% das empresas com essa estratégia deram lucro" — porque as que faliram não estão no banco de dados.
- **Viés de cobertura:** pesquisa por telefone fixo, questionário aplicado só em shopping, formulário online em região sem internet.
- **Viés do entrevistador / desejabilidade social:** a pergunta induz a resposta. "Você é a favor de acabar com os privilégios de X?" não mede a mesma coisa que "Você é a favor da proposta X?".

Amostra viesada é o único erro estatístico que não melhora quando você aumenta a amostra. Dez mil respostas de uma amostra torta são dez mil respostas tortas — apenas com uma falsa aparência de autoridade.

Parte 6 · O protocolo de autodefesa

Você não precisa desconfiar de tudo. Precisa de uma checagem de cinco segundos, aplicada **sempre na mesma ordem**:

Pergunte	Você está caçando
1. O eixo y começa em zero?	Eixo truncado; diferença amplificada.
2. Os rótulos são igualmente espaçados?	Escala logarítmica ou irregular oculta.
3. É contagem ou taxa?	Comparação entre grupos de tamanhos diferentes.
4. Por que o recorte começa aí?	Cherry-picking de intervalo ou de classe.
5. Quem foi medido — e quem não foi?	Viés de amostragem, sobrevivente, autosseleção.

Cinco perguntas. Elas não exigem uma única conta, e desarmam a maior parte do que você vai ler pelo resto da vida.

A REGRA DO JOGO

O que você leva desta aula para a prova

1. **Não existe gráfico neutro.** Todo gráfico embute escolhas invisíveis (origem do eixo, largura de classe, recorte, amostra). Dados corretos + representação escolhida = conclusão falsa.
2. **Eixo truncado** (não começando em zero) amplifica diferenças pequenas. É a fraude nº 1 e a mais fácil de detectar: olhe o primeiro rótulo do eixo y.
3. **Em gráfico de barras e histograma, a percepção compara área**, não posição de topo. Por isso truncar destrói a proporcionalidade.
4. **Histograma ≠ gráfico de barras:** histograma é para variável quantitativa contínua, barras encostadas, ordem fixa, e a informação está na **área**. Barras é para categorias, separadas, reordenáveis, informação na altura.
5. **Tabela de frequência:** f_i (absoluta), $f_r = f_i/n$ (relativa, a única comparável entre grupos), F_i (acumulada, dá mediana e quartis), amplitude de classe h e ponto médio (representante da classe).
6. **A largura de classe cria a forma da distribuição.** Bimodalidade ou assimetria só é fenômeno se sobreviver à mudança de h; caso contrário é artefato.
7. **Pictogramas escalados** multiplicam a área por k^2 e o volume por k^3 (retoma 4.5) — exageram enormemente o dado.
8. **Contagem bruta nunca compara grupos de tamanhos diferentes.** Use taxa / frequência relativa.
9. **Viés de amostragem** (autosseleção, sobrevivente, cobertura, desejabilidade social) é invisível no gráfico e **não é corrigido por amostra maior**.
10. **Correlação visual não é correlação; correlação não é causalidade.** Eixos duplos com escalas ajustadas fabricam relação onde não há.

OQPS — A LINHA DE CHEGADA

Sem consultar. Respostas curtas e técnicas.

1. Explique o mecanismo do eixo truncado e por que ele distorce a percepção mesmo quando todos os valores plotados estão corretos.
2. Diferencie histograma de gráfico de barras quanto ao tipo de variável, ao contato entre as barras e ao atributo visual que carrega a informação.
3. Defina frequência absoluta, relativa e acumulada, indicando qual delas é obrigatória para comparar dois grupos de tamanhos diferentes e por quê.
4. Justifique por que a escolha da amplitude de classe pode fazer uma distribuição parecer bimodal, e qual teste você aplica para decidir se a bimodalidade é real.
5. Explique por que aumentar o tamanho da amostra não corrige o viés de amostragem, citando dois tipos de viés.

GABARITO OQPS

1. O eixo truncado é o gráfico cujo eixo vertical não se inicia em zero. Como a leitura visual de barras compara **áreas** (ou comprimentos) e não a posição absoluta dos topos, truncar rompe a proporcionalidade entre o comprimento desenhado e o valor representado: uma diferença de 0,3 ponto pode ocupar três vezes mais altura. Os valores permanecem verdadeiros, mas o **encoding visual** passa a representar a diferença em relação à baseline arbitrária, e não a magnitude do dado.
2. **Gráfico de barras:** variável qualitativa ou discreta (categorias), barras **separadas**, ordem arbitrária/reordenável, informação na **altura**. **Histograma:** variável quantitativa **contínua** agrupada em classes, barras **encostadas** (intervalos contíguos formando uma reta numérica), ordem fixa, informação na **área** do retângulo (altura × amplitude de classe).
3. **Absoluta** (f_i): número de observações na classe. **Relativa** ($f_r = f_i/n$, em % ou fração): proporção da classe no total. **Acumulada** (F_i): soma das frequências até a classe, usada para localizar mediana e quartis. Para comparar grupos de tamanhos diferentes é obrigatória a **relativa**, porque só ela remove o efeito do tamanho do grupo — comparação legítima entre conjuntos desiguais é multiplicativa (razão), não aditiva (contagem).
4. Porque a amplitude de classe é uma escolha arbitrária que define quanta informação é agregada: classes estreitas expõem flutuações aleatórias que podem formar dois picos espúrios, e classes largas podem fundir dois picos reais num só. O teste é de **robustez**: reagrupar os dados com várias amplitudes diferentes. Se a bimodalidade persiste, é fenômeno; se desaparece ao mudar h, é artefato do agrupamento.
5. Porque o viés é um erro **sistemático** no processo de coleta, não um erro aleatório: a amostra converge para o parâmetro de uma subpopulação distorcida, e não para o da população-alvo. Aumentar n reduz apenas o erro aleatório, tornando a estimativa **mais precisa em torno do valor errado**. Exemplos: **autosseleção** (enquete online, respondida só por quem tem opinião intensa) e **viés do sobrevivente** (analisar apenas os casos que restaram, excluindo os fracassos do banco de dados).

A RESPOSTA, EM UMA FRASE

Um gráfico mente sem falsificar nenhum número porque a mentira não está nos dados, e sim nas escolhas de representação que ninguém declara — origem do eixo, largura de classe, recorte temporal, contagem em vez de taxa e composição da amostra —, escolhas que o seu sistema visual aceita como percepção antes de a sua crítica ter chance de intervir.

E agora você chega ao caso mais difícil de todos — porque parece o mais absurdo:

> *Um instituto entrevista **2.014 pessoas** e afirma, na televisão, algo sobre **156 milhões de eleitores**. Publica: "42%, com margem de erro de 2 pontos". Sua reação natural é a de qualquer pessoa sensata: **é impossível; ninguém me perguntou nada.***
>
> *Só que é possível, é matematicamente demonstrável, e o número que faz isso funcionar é o desvio padrão que você calculou em 8.13. Em **8.15** você vai entender de onde vem a margem de erro, por que dobrar a amostra não dobra a precisão, o que é a curva normal e a regra 68–95–99,7 — e por que "empate técnico" é uma afirmação técnica precisa, não um jeito educado de fugir da pergunta.*

A seguir: 8.15 — Como se pode afirmar algo sobre 200 milhões de pessoas ouvindo apenas 2 mil?