EIXO VIII · LER DADOS SEM SER ENGANADO — AULA 8.15

Como se pode afirmar algo sobre 200 milhões de pessoas ouvindo apenas 2 mil?

> *Você não precisa beber o oceano inteiro para saber que ele é salgado. Mas precisa saber duas coisas que quase ninguém sabe: que o tamanho da população é irrelevante, e que a precisão custa o quadrado do dinheiro.*

Aula 8.15 — A amostra, o sino e a margem de erro

A ÂNCORA

Domingo à noite, telejornal. Rodapé da tela:

> ***Candidato A: 42% · Candidato B: 38%***
> *2.014 entrevistados · margem de erro: 2 pontos percentuais · 95% de confiança*

Na mesa de casa, o comentário previsível: "Isso não vale nada. Duas mil pessoas num país de 156 milhões de eleitores? Ninguém nunca me perguntou nada."

O argumento parece devastador. $2.014 / 156.000.000 \approx 0,0013\%$. Treze milionésimos da população. Como é que treze milionésimos podem falar pelo resto?

E o mais irritante: **essas pesquisas costumam acertar.** Não sempre, não perfeitamente — mas com uma frequência que uma adivinhação não teria. Alguma coisa está funcionando, e não é sorte.

Você vai descobrir o que é. E vai descobrir um fato que soa como erro de digitação:

Para uma amostra bem construída, o tamanho da população praticamente não afeta a precisão. Uma amostra de 2.000 pessoas mede uma cidade de 50 mil e um país de 200 milhões com a mesma margem de erro.

A DESCONSTRUÇÃO

O senso comum diz: "amostra tem que ser proporcional ao tamanho do país". É a intuição da fatia de pizza — se o bolo é maior, a fatia representativa tem que ser maior.

Está errado, e o erro é de categoria: você está aplicando raciocínio de **proporção** (Eixo I) num problema que é de **variabilidade**.

A ANALOGIA QUE DESMONTA A INTUIÇÃO

Você prova um caldeirão de sopa para saber se está salgado. Uma colher basta.

Agora imagine um caldeirão **dez vezes maior**. Quantas colheres você precisa? Ainda uma.

O que determina se a colher informa não é o volume da panela — é se a sopa está **bem mexida**. Se estiver estratificada (sal no fundo), nem meio litro resolve. Se estiver homogênea, uma colher basta para qualquer tamanho de panela.

Traduzindo: "bem mexida" = amostragem aleatória. "Volume da panela" = tamanho da população, irrelevante. O que importa é o **tamanho da colher** (n) e a **heterogeneidade da sopa** (o desvio padrão de 8.13).

Note que o problema mudou de natureza. A pergunta deixou de ser "que fração da população eu ouvi?" e passou a ser: **se eu repetisse esta pesquisa mil vezes, quanto os resultados variariam entre si?** Essa é uma pergunta de dispersão — e você já tem a ferramenta para responder.

A ENGENHARIA DO CONCEITO

Parte 1 · População, amostra e os quatro modos de sortear

VOCABULÁRIO OBRIGATÓRIO

- **População:** o conjunto inteiro sobre o qual você quer concluir (156 milhões de eleitores).
- **Amostra:** o subconjunto efetivamente medido (2.014 pessoas).
- **Parâmetro:** o valor real, verdadeiro, desconhecido na população. Notação: μ, σ, p.
- **Estatística (ou estimador):** o valor calculado na amostra. Notação: $\overline{x}$, s, $\hat{p}$.
- **Censo:** medir a população inteira. Caro, lento e — surpresa — nem sempre mais preciso, porque um censo de 200 milhões acumula erros de coleta que uma amostra pequena e bem-feita evita.

O verbo central aqui é **sortear**. Amostra sem sorteio é amostra viesada (você viu em 8.14), e viés não se corrige com tamanho. Quatro técnicas legítimas:

Técnica	Como funciona	Quando é a escolha certa
Aleatória simples	Sorteio puro: todo elemento tem a mesma chance. É o "nome no chapéu".	Padrão-ouro teórico. Exige lista completa da população — raro.
Sistemática	Ordena a lista e pega de k em k (a cada 50º nome), com início sorteado.	Linha de produção, fila, cadastro. Simples e barata. **Cuidado:** falha se a lista tiver periodicidade.
Estratificada	Divide a população em **estratos homogêneos** (sexo, renda, região) e sorteia dentro de cada um, proporcionalmente.	Quando você sabe que os grupos diferem. **Aumenta a precisão** sem aumentar n.
Por conglomerados	Divide em **grupos geográficos** (bairros, escolas), sorteia alguns grupos e mede **todos** dentro deles.	Quando deslocamento é caro. Mais barata, porém **menos precisa**.

A DISTINÇÃO QUE A PROVA COBRA

Estratificada e conglomerados parecem iguais e são opostas na lógica:

- **Estratos:** internamente **homogêneos**, diferentes entre si. Você sorteia **dentro de todos** os estratos. Objetivo: precisão.
- **Conglomerados:** internamente **heterogêneos**, parecidos entre si (cada bairro é um mini-Brasil). Você sorteia **quais** conglomerados usar. Objetivo: custo.

Parte 2 · O fato mágico: a distribuição das médias vira um sino

Aqui está o coração da aula. Faça o seguinte experimento mental:

Sorteie 2.000 eleitores e calcule a porcentagem de A. Deu 42,3%. Devolva todos, sorteie **outros** 2.000. Deu 41,7%. De novo: 42,9%. De novo: 41,1%.

Repita mil vezes e faça o histograma desses mil resultados (você aprendeu a construí-lo em 8.14). Não importa se a variável original é torta, bimodal, assimétrica ou grotesca: **o histograma das médias amostrais tem forma de sino**, centrado no valor verdadeiro.

Esse é o resultado mais importante da estatística. Ele tem nome, **Teorema Central do Limite**, e a consequência prática é brutal: você não precisa saber como a população se distribui para saber como o seu **erro** se distribui.

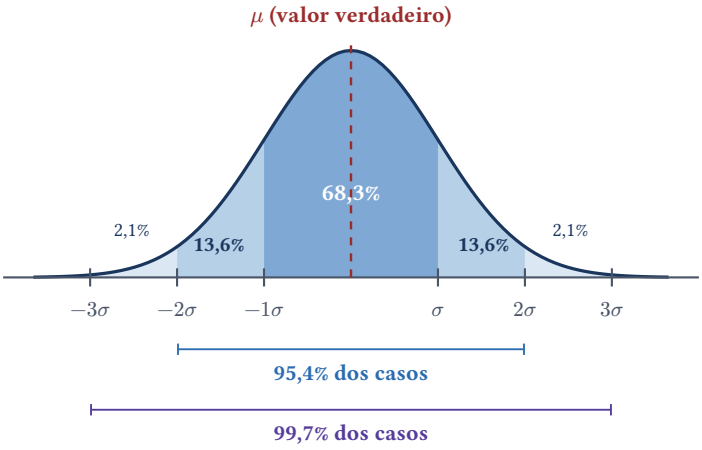


Fig. 1 — A regra empírica **68–95–99,7**. O que a torna útil não é a forma do sino, e sim o fato de que o desvio padrão **funciona como régua**: a distância até a média, medida em unidades de σ, determina a probabilidade — e essa correspondência é a mesma para toda curva normal, seja de altura de recrutas, erro de medida ou resultado de pesquisa eleitoral. Repare também que a área é toda a probabilidade: sair de 2σ para 3σ acrescenta pouquíssimo, porque as caudas são finas. Eventos a mais de 3σ da média são raros — e é por isso que, em ciência, "3σ" virou sinônimo de "provavelmente não foi acaso".

AS TRÊS PROPRIEDADES DA NORMAL QUE VOCÊ PRECISA RECONHECER

1. **Simétrica** em torno da média — logo média = mediana = moda.
2. **Dois parâmetros e nada mais:** μ posiciona o sino (translação, 3.15) e σ controla a largura (dilatação, 3.15). Toda normal é a mesma curva transformada.
3. **Área total = 1**, e as áreas obedecem a 68–95–99,7. É aqui que 8.13 se paga: sem desvio padrão, a normal é um desenho bonito e inútil.

Parte 3 · Por que a população não entra na conta

Agora o número que responde a âncora. A dispersão das médias amostrais — o quanto seu resultado balança de pesquisa para pesquisa — é o **erro padrão**:

$$\text{erro padrão} = \frac{\sigma}{\sqrt{n}}$$

Olhe fixamente para essa fórmula e procure o tamanho da população. **Ele não está lá.** Só aparecem a heterogeneidade da população (σ) e o tamanho da sua amostra (n). Isso é a resposta matemática ao comentário do telejornal.

E há uma segunda leitura, ainda mais reveladora: o n está **sob uma raiz**.

Amostra n	Margem de erro (aprox., 95%)	Custo relativo
400	$\pm 5,0$ p.p.	1×
1.000	$\pm 3,1$ p.p.	2,5×
2.000	$\pm 2,2$ p.p.	5×
4.000	$\pm 1,6$ p.p.	10×
10.000	$\pm 1,0$ p.p.	25×

Para dobrar a precisão você precisa quadruplicar a amostra. Precisão custa o quadrado do dinheiro — e é exatamente por isso que os institutos param perto de 2.000: ali a curva de retorno já achatou.

Parte 4 · O que "margem de erro de 2 pontos, 95% de confiança" realmente diz

Traduzindo a frase palavra por palavra:

LEITURA CORRETA

"Se eu repetisse este procedimento de amostragem muitas vezes, em cerca de **95%** delas o intervalo construído conteria o valor verdadeiro."

Para o resultado 42% com margem de 2 p.p., o **intervalo de confiança** é:

$$[42 - 2; 42 + 2] = [40\%; 44\%]$$

A leitura honesta não é "o candidato tem 42%". É: **"o candidato tem algo entre 40% e 44%, e eu poderia estar entre os 5% de azarados."**

TRÊS ERROS DE INTERPRETAÇÃO QUE VALEM ZERO NA PROVA

- **"95% de chance de o valor verdadeiro estar aqui."** Impreciso: o valor verdadeiro é fixo, não sorteado. Quem varia é o intervalo. A confiança é do **método**, não daquele intervalo específico.
- **"A margem de erro cobre todos os erros da pesquisa."** Não. Ela cobre **apenas** o erro aleatório de amostragem. Viés, pergunta mal formulada, entrevistado que mente e recusa em responder ficam **fora** dela — e podem ser muito maiores.
- **"Margem de 2 pontos, então a diferença de 4 pontos é segura."** Cuidado: a margem se aplica a **cada** candidato. Se A pode cair para 40 e B pode subir para 40, a diferença pode ser zero.

Parte 5 · "Empate técnico" não é covardia de jornalista

É afirmação técnica precisa, e agora você consegue construí-la.

$A = 42\%$ e $B = 38\%$, margem ± 2 p.p.

- Intervalo de A: $[40; 44]$
- Intervalo de B: $[36; 40]$

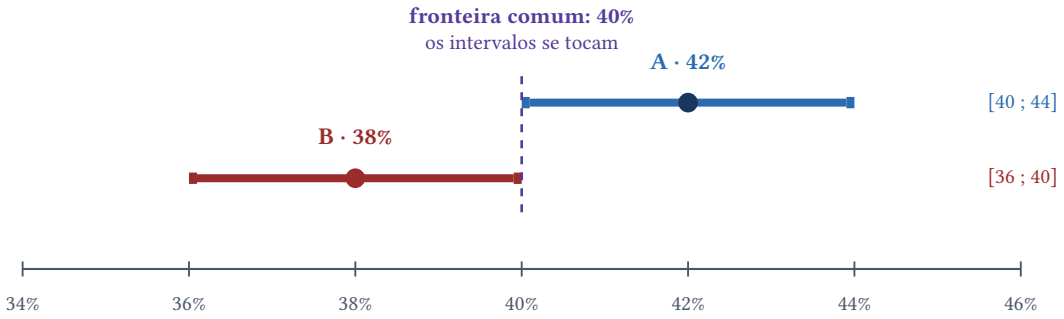


Fig. 2 — Sobreposição de intervalos: **empate técnico**. O ponto sutil que quase todo mundo perde é que a comparação nunca deve ser feita entre os **valores centrais** (42 contra 38), mas entre os **intervalos inteiros**. Note ainda que ordenar A acima de B seria uma conclusão que os dados não sustentam: existe um cenário compatível com a pesquisa em que ambos valem 40%. Uma diferença só é estatisticamente sustentada quando os intervalos ficam **separados** — o que aqui exigiria distância maior que a soma das duas margens.

Existe um cenário compatível com os dados em que os dois têm 40%. Portanto a pesquisa **não autoriza** dizer que A está na frente. Isso não é indecisão do instituto: é o instituto se recusando a afirmar mais do que mediu — que é, no fim, tudo o que este eixo inteiro tentou te ensinar.

A REGRA DO JOGO

O que você leva desta aula para a prova

1. **Parâmetro** (μ, σ, p) é da população e é desconhecido; **estatística** ($\overline{x}$, s, $\hat{p}$) é da amostra e é o que você calcula. Inferência é usar a segunda para estimar o primeiro.
2. **O tamanho da população não afeta a precisão.** Erro padrão $= \sigma/\sqrt{n}$: só entram a heterogeneidade e o tamanho da amostra.
3. **Precisão custa o quadrado:** dobrar a precisão exige quadruplicar n.
4. **Estratificada × conglomerados:** estratos são internamente homogêneos e você sorteia dentro de todos (ganha precisão); conglomerados são internamente heterogêneos e você sorteia quais usar (ganha custo).
5. **Amostragem sistemática** pega de k em k com início sorteado; falha se a lista tiver periodicidade oculta.
6. **Teorema Central do Limite:** qualquer que seja a distribuição original, a distribuição das médias amostrais tende ao **sino**, centrada no valor verdadeiro.
7. **Normal:** simétrica (média = mediana = moda), definida só por μ (posição) e σ (largura), área total 1.
8. **Regra empírica 68–95–99,7:** essas são as proporções dentro de $\pm 1\sigma$, $\pm 2\sigma$ e $\pm 3\sigma$. O desvio padrão é a régua da probabilidade.
9. **Intervalo de confiança** = estimativa $\pm$ margem de erro. Os 95% descrevem a confiabilidade do **método**, não a chance de aquele intervalo específico estar certo.
10. **A margem de erro só cobre erro aleatório de amostragem.** Viés, recusa e pergunta enviesada estão fora dela — e não diminuem com n maior.
11. **Empate técnico** = intervalos de confiança sobrepostos. Compare intervalos, nunca valores centrais.

OQPS — A LINHA DE CHEGADA

Sem consultar. Respostas curtas e técnicas.

1. Explique, com base na expressão do erro padrão, por que o tamanho da população não influencia a precisão de uma amostra aleatória — e o que de fato a influencia.
2. Diferencie amostragem estratificada de amostragem por conglomerados quanto à homogeneidade interna dos grupos, ao que é sorteado e ao objetivo de cada uma.
3. Enuncie a regra empírica 68–95–99,7 e explique por que ela só é utilizável se você conhecer o desvio padrão.
4. Traduza tecnicamente a expressão "margem de erro de 2 pontos com 95% de confiança", e cite um tipo de erro de pesquisa que essa margem **não** cobre.
5. Defina empate técnico e explique por que uma diferença de 4 pontos entre dois candidatos pode não ser estatisticamente sustentada com margem de ± 2 p.p.

GABARITO OQPS

1. O erro padrão é $\sigma/\sqrt{n}$ — e o tamanho da população não figura na expressão. A precisão depende apenas de (i) σ, a heterogeneidade da população (populações mais uniformes exigem amostras menores) e (ii) n, o tamanho da amostra. Como n está sob a raiz, o ganho é decrescente: dobrar a precisão exige quadruplicar n.
2. **Estratificada:** estratos internamente **homogêneos** e diferentes entre si; sorteiam-se elementos **dentro de todos** os estratos, proporcionalmente; objetivo é **aumentar a precisão** sem aumentar n. **Conglomerados:** grupos internamente **heterogêneos** e semelhantes entre si (cada um é um mini-retrato da população); sorteiam-se **quais grupos** entram e medem-se todos os seus elementos; objetivo é **reduzir custo** de deslocamento, ao preço de menor precisão.
3. Numa distribuição normal, aproximadamente **68,3%** dos dados estão em $[\mu-\sigma;\mu+\sigma]$, **95,4%** em $[\mu-2\sigma;\mu+2\sigma]$ e **99,7%** em $[\mu-3\sigma;\mu+3\sigma]$. Ela só é utilizável com o desvio padrão porque σ é a **unidade de medida** da regra: as porcentagens correspondem a distâncias contadas em múltiplos de σ. Sem σ, saber onde está o centro (μ) não permite converter distância em probabilidade.
4. Significa que, se o procedimento de amostragem fosse repetido muitas vezes, em cerca de 95% das repetições o intervalo construído (estimativa ± 2 p.p.) conteria o valor verdadeiro da população. A confiança é uma propriedade do **método**, não daquele intervalo isolado. Ela cobre **somente o erro aleatório de amostragem**; ficam fora, por exemplo, o **viés de amostragem** (e também recusa em responder, pergunta enviesada, entrevistado que mente) — erros sistemáticos que não diminuem ao aumentar n.
5. **Empate técnico** é a situação em que os intervalos de confiança dos dois candidatos se **sobrepõem**, de modo que existe um valor compatível com ambos e a pesquisa não autoriza afirmar qual está à frente. Com $A=42\%$ e $B=38\%$ e margem ± 2 p.p., os intervalos são $[40;44]$ e $[36;40]$: eles se tocam em 40%, cenário no qual os dois estariam iguais. A margem aplica-se a **cada** estimativa separadamente, e por isso a comparação deve ser feita entre intervalos inteiros — nunca entre os valores centrais.

A RESPOSTA, EM UMA FRASE

Pode-se afirmar algo sobre 200 milhões de pessoas ouvindo 2 mil porque o que limita a precisão não é a fração da população examinada, e sim a variabilidade da população dividida pela raiz do tamanho da amostra — e porque o Teorema Central do Limite garante que o erro dessa estimativa se distribui como um sino, permitindo traduzir o desvio padrão em uma margem de erro com confiança declarada.

Você termina aqui o Eixo VIII com uma competência que a maioria dos adultos deste país não tem: sabe contar sem listar, medir chance, resumir dados, detectar gráfico mentiroso e ler uma pesquisa eleitoral pelo que ela realmente diz.

E chega ao fim com uma sensação de terreno firme — todo número tem seu lugar na reta, toda equação tem sua solução localizável. Guarde essa sensação, porque a próxima aula a destrói:

> *Existe uma equação, ridiculamente simples, escrita com os símbolos mais banais que você conhece:* $x^2+1=0$.
>
> *Ela não tem solução em* $\mathbb{R}$. *Nenhuma. E não por dificuldade técnica — por* ***impossibilidade estrutural****: nenhum número real elevado ao quadrado resulta negativo.*

> *A humanidade já fez isso antes. Quando a subtração estourou $\mathbb{N}$, inventou os negativos (1.1); quando a divisão estourou $\mathbb{Z}$, inventou as frações. Agora a radiciação estourou $\mathbb{R}$. No **Eixo IX** você vai ver o último — e mais audacioso — desses movimentos: a invenção de um número cujo quadrado é -1, e a descoberta espantosa de que esse "número imaginário" não é abstração inútil nenhuma. É uma **rotação de 90°** no plano de 6.9.*

A seguir: Eixo IX — A Fronteira: quando os números acabam e a matemática continua.